

Projet MT Darija: du Silver au Gold

QC hybride, cleaning robuste et recommandations MLOps/IA

Equipe Traduction NLP

Projet R&D Machine Translation

13 avril 2026

Plan

- 1 Introduction et problématique
- 2 Vue d'ensemble du pipeline
- 3 Role de chaque script
- 4 Resultats et points forts
- 5 Recommandations MLOps
- 6 Pistes IA / ML / Deep Learning
- 7 Conclusion

- La Darija est une langue *low-resource* pour la traduction automatique.
- Le projet vise une transformation **Silver** → **Gold** avec validation humaine.
- Les données sont multilingues : Darija (arabe + arabizi), anglais et arabe standard (MSA).
- Le besoin principal : augmenter la qualité sans exploser les coûts API.

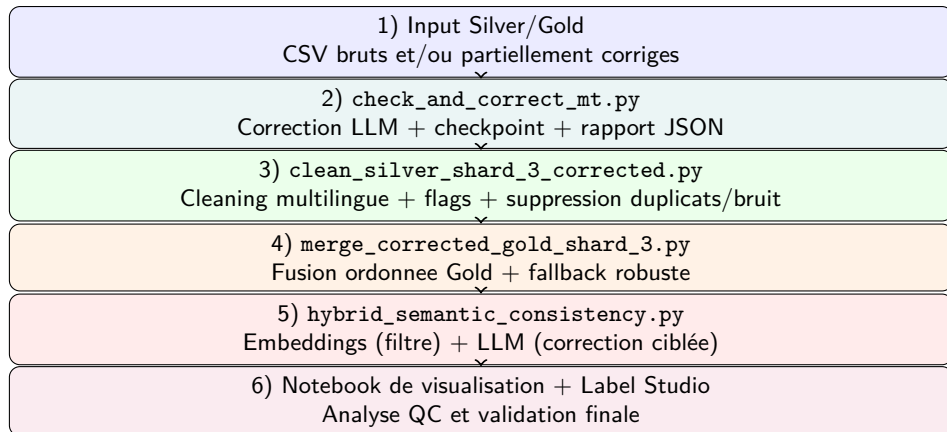
- **Qualite heterogene** : artefacts MT, incoherences semantiques, bruit web.
- **Alignement multilingue fragile** : meme phrase, 4 representations differentes.
- **Scalabilite** : 9k+ lignes silver et 1k lignes gold a traiter.
- **Reproductibilite** : reprise sur panne, traces des modifications, rapports exploitables.

Question centrale : comment construire un pipeline fiable, economique et audit-able pour livrer un corpus MT de haute qualite ?

Objectifs du projet

- Automatiser la correction et la validation sémantique avec **human-in-the-loop**.
- Normaliser et nettoyer les textes avec des règles linguistiques robustes.
- Produire des artefacts finaux exploitables pour l'entraînement MT.
- Mesurer la qualité (flags, similarité, rapports) et préparer la phase de modélisation.

Pipeline complet du projet



Script 1 : `check_and_correct_mt.py`

Mission : correction QC automatique des 4 champs MT avec OpenAI.

- Validation/correction de : `darija_arabic`, `darija_arabizi`, `english`, `modern_standard_arabic`.
- Concurrency via `ThreadPoolExecutor` et rate limiting (RPM/TPM).
- Checkpoint JSONL : reprise sans retraiter les lignes déjà faites.
- Sorties : CSV corrige + rapport JSON (tokens, cout estime, erreurs, champs modifies).
- Mode dry-run pour tester les prompts avant ecriture.

Script 2 : clean_silver_shard_3_corrected.py

Mission : nettoyage linguistique avance et controle qualite ligne par ligne.

- Normalisation texte : artefacts, espaces, ponctuation, bruit web/email/mentions.
- Nettoyage specifique Darija/Arabizi/English/MSA + stopwords configurables.
- Detection d'anomalies : mismatch script, incoherence Darija-Arabizi, longueurs extremes.
- Gestion statut de sortie : CLEAN, FLAGGED, REMOVED.
- Rapport complet : synthese issues, champs modifies, seuils et configuration.

Script 3 : merge_corrected_gold_shard_3.py

Mission : fusionner proprement les moities corrigees du Gold shard.

- Normalise les schemas (standard vs export Label Studio corrected_*).
- Respecte l'ordre canonique des 1000 lignes Gold.
- Controle les champs textes obligatoires non vides.
- Strategie de fallback pour eviter des trous quand IDs non alignes.
- Produit : CSV fusionne + rapport JSON de matching et warnings.

Script 4 : `hybrid_semantic_consistency.py`

Mission : verifier la coherence semantique de maniere hybride et economique.

- Etape A : embeddings pour score de similarite multi-paires.
- Etape B : appel LLM seulement si score $<$ threshold.
- Flags de sortie : CONSISTENT, SUSPICIOUS, CORRECTED.
- Checkpoint + reprise, retries, rate limiting, visualisations PNG.
- Rapport final : volumes, cout LLM, similarite moyenne, lignes corrigees.

Notebook et interface d'annotation

Hybrid_Semantic_QC_Visualization.ipynb

- Charge les artefacts Silver/Gold disponibles.
- Compare distribution des flags et histogrammes de similarite.
- Resume les KPI du rapport hybride (rows, cout, corrections).

Labeling_Interface.xml

- Interface Label Studio moderne en 2 panneaux (source/target).
- Champs de correction dedies pour Darija arabe, Arabizi, English, MSA.
- Decision finale VALIDATED + commentaire annotateur.

Resultats chiffres (artefacts actuels)

Etape	Indicateurs clés
Silver merge final	9005 lignes, 8860 lignes modifiees, 145 inchangées, 0 erreurs restantes.
Cleaning strict	9005 traitees, 6382 CLEAN, 2600 FLAGGED, 23 REMOVED.
Cleaning balanced	9005 traitees, 8993 CLEAN, 12 FLAGGED, 0 REMOVED.
Gold merge	1000 lignes sortie, warning d'incoherence IDs sur la 1ere moitie, fall-back actif.
Gold hybrid QC	1000 lignes, 728 corrigees, 270 consistantes, cout estime \$0.6577.

Point fort principal : pipeline hybride semantics + QC

- Architecture **filtre embeddings + correction LLM** tres pertinente pour reduire le cout.
- Capacite industrielle : retries, checkpoint, parallelisme, rapporting JSON, visualisation.
- Compatibilite annotation humaine (Label Studio) pour garder la qualite linguistique.

Cout LLM estime :

$$\text{Cost} = \frac{T_{in}}{10^6} \times P_{in} + \frac{T_{out}}{10^6} \times P_{out}$$

ou T_{in} , T_{out} sont les tokens prompt/completion et P_{in} , P_{out} les prix par million de tokens.

Limites observees et risques

- Seuil unique de similarite peut surdeclencher les appels LLM (cas Gold : 998/1000 lignes suspectes).
- Forte variabilite linguistique Darija $\leftrightarrow$ Arabizi complique les regles strictes.
- Dependance a la cle API pour certaines etapes critiques.
- Besoin d'un protocole d'evaluation modele (BLEU/chrF/BERTScore/COMET) encore a industrialiser.

Architecture MLOps recommandee

- **Data Versioning** : DVC + stockage objet (S3/MinIO) pour CSV et checkpoints.
- **Experiment Tracking** : MLflow ou Weights&Biases (params, metrics, artefacts).
- **Pipeline Orchestration** : Prefect ou Airflow pour enchaîner QC, cleaning, hybrid check, training.
- **Model Registry** : versionnement des modeles MT finetunes et promotion staging/prod.
- **CI/CD** : GitHub Actions pour tests data, lint, validation schema, build des rapports.
- **Monitoring** : quality drift, cout API, taux SUSPICIOUS, latence inference.

Plan d'implementation MLOps (propose)

- 1 Standardiser contrats de donnees (schema, valeurs de status, checks auto).
- 2 Encapsuler chaque script en job reproductible avec config YAML.
- 3 Centraliser metriques et artefacts dans MLflow/W&B.
- 4 Ajouter tests automatiques de non-regression linguistique (sample fixe).
- 5 Mettre en place un dashboard de suivi qualite/cout hebdomadaire.

Baselines MT supervisees

- AraT5v2, mT5, NLLB-200, MADLAD-400 (seq2seq multilingue).
- Fine-tuning directionnel : Darija $\rightarrow$ English, Darija $\rightarrow$ MSA.

Optimisation entraînement

- LoRA / QLoRA pour reduire cout GPU.
- Curriculum learning selon la classe de longueur (A/B/C/D).
- Back-translation pour enrichir les paires paralleles.

- **Quality Estimation** : COMET-Kiwi pour predire la qualite sans reference.
- **Active Learning** : prioriser annotation humaine sur lignes les plus incertaines.
- **Semantic Retrieval** : LaBSE/SBERT pour detection de paraphrases ou duplicats semantiques.
- **Error Classification** : modele de classification des types d'erreurs (lexicale, registre, entites, etc.).

- Le projet a déjà une base technique solide et reproductible pour passer de Silver à Gold.
- Le point fort est le **pipeline hybride** qui combine vitesse, coût maîtrisé et qualité.
- Prochaine étape naturelle : industrialiser avec MLOps puis entraîner/benchmarkner les modèles MT.

Résultat attendu : un corpus Darija MT fiable + une chaîne de production mesurable et évolutive.

Merci pour votre attention