

Rapport Technique Complet QC et Cleaning des Donnees MT

Projet Traduction

06 Avril 2026

Table des matières

1	Objectif du rapport	2
2	Perimetre et artefacts analyses	2
2.1	Scripts principaux	2
2.2	Rapports JSON utilises	2
3	Bibliotheques et dependances	2
3.1	Dependances declarees (requirements.txt)	2
3.2	Imports effectifs dans les scripts	2
4	Script 1 : check_and_correct_mt.py	3
4.1	Role	3
4.2	Architecture technique	3
4.3	Parametres CLI majeurs	3
4.4	Resultats QC (silver shard 3)	3
4.5	Problemes observes sur le QC	4
5	Script 2 : clean_silver_shard_3_corrected.py	4
5.1	Role	4
5.2	Nettoyages appliques (detail fonctionnel)	4
5.2.1	Preprocessing global	4
5.2.2	Nettoyage par langue	4
5.2.3	Filtres de lignes	5
5.2.4	Post-clean quality fixes	5
6	Resultats de cleaning (rapports JSON)	5
6.1	Silver cleaned (mode strict)	5
6.2	Gold cleaned (conservation MSA-Darija)	5
7	Resultat intermediaire merge gold	6
8	Interpretation des resultats EDA comparatifs	6
8.1	Vue d ensemble volumes et retention	6
8.2	Evolution des statuts	6
8.3	Taux de changement texte (source vs cleaned)	7
8.4	Longueur des textes et outliers	7
9	Pipeline global du projet	7
9.1	Pipeline fonctionnel	7
9.2	Pipeline resume	8

10 Problemes techniques constates	8
11 Recommandations	8
12 Commandes de reproduction	8
12.1 QC principal silver	8
12.2 Cleaning silver (mode strict par default)	9
12.3 Cleaning gold en gardant MSA-Darija	9
13 Appendice A : extraits JSON utiles	9
13.1 QC summary (silver)	9
13.2 Cleaning summary (silver strict)	9
13.3 Cleaning summary (gold keep-msa-darija-leakage)	9

1 Objectif du rapport

Ce document decrit de maniere technique et reproductible :

- le fonctionnement de `check_and_correct_mt.py`,
- le fonctionnement de `clean_silver_shard_3_corrected.py`,
- les bibliotheques utilisees,
- les regles de cleaning appliquees,
- les resultats obtenus a partir des rapports JSON,
- les problemes observes et les ameliorations recommandees.

2 Perimetre et artefacts analyses

2.1 Scripts principaux

- `check_and_correct_mt.py`
- `clean_silver_shard_3_corrected.py`

2.2 Rapports JSON utilises

- `artifacts/silver_shard_3_qc/silver_shard_3.corrected.auto.report.json`
- `artifacts/silver_shard_3_cleaned/cleaning_report.json`
- `artifacts/gold_shard_3_cleaned/cleaning_report.json`
- `artifacts/gold_shard_3_merge/gold_shard_3.merge_report.json`

3 Bibliotheques et dependances

3.1 Dependances declarees (requirements.txt)

Package	Version minimale	Usage principal
openai	>=1.0.0	Appels modele LLM (QC)
pandas	>=2.0.0	Lecture/manipulation CSV
tqdm	>=4.65.0	Barre de progression
python-dotenv	>=1.0.0	Declaree, non utilisee directement
nltk	>=3.8.1	Stopwords, stemming, lemmatisation
pydantic	>=2.6.0	Validation schema JSON de sortie

3.2 Imports effectifs dans les scripts

Dans `check_and_correct_mt.py` :

- standard library : `argparse`, `csv`, `json`, `os`, `re`, `sys`, `threading`, `time`, `pathlib`, `dataclasses`, `datetime`, `typing`
- externes : `openai`, `pydantic`, `tqdm`
- parallellisme : `ThreadPoolExecutor` (concurrent futures)

Dans `clean_silver_shard_3_corrected.py` :

- standard library : `argparse`, `html`, `json`, `re`, `unicodedata`, `collections.Counter`, `pathlib`, `dataclasses`, `typing`
- externes : `pandas`, `nltk` (`stopwords`, `PorterStemmer`, `WordNetLemmatizer`)

4 Script 1 : check_and_correct_mt.py

4.1 Role

Ce script realise un controle qualite multilingue (Darija arabe, Darija arabizi, anglais, MSA), corrige les champs texte via LLM, puis produit :

- un CSV corrige,
- un rapport JSON detaille,
- un checkpoint JSONL pour reprise/resume.

4.2 Architecture technique

- **Prompting et few-shot** : variable `FEW_SHOT_EXAMPLES` et construction via `build_messages`.
- **Validation schema** : reponse forcee en `json_object` puis validee par Pydantic (`QCResponse`, `FieldResult`).
- **Rate limiting** : classe `TokenBucket` pour RPM/TPM.
- **Concurrence** : `ThreadPoolExecutor` pour traiter plusieurs lignes en parallele.
- **Robustesse** : retries differencies (`RateLimitError`, `APIError`, erreurs JSON).
- **Reprise** : checkpoint incremental et saut des lignes deja traitees.

4.3 Parametres CLI majeurs

- chemins : `-input`, `-output`, `-report`, `-artifacts-dir`, `-checkpoint`
- modele/API : `-api-key`, `-env-file`, `-model`
- controle du batch : `-start-row`, `-end-row`, `-max-rows`, `-only-status`
- performance : `-workers`, `-rpm`, `-tpm`, `-retries`
- mode : `-dry-run`, `-output-style`

4.4 Resultats QC (silver shard 3)

Source : `artifacts/silver_shard_3_qc/silver_shard_3.corrected.auto.report.json`

Indicateur	Valeur
Modele	<code>gpt-4.1-mini</code>
Total lignes	9005
Lignes traitees	9005
Lignes modifiees	8856
Lignes en erreur	4
Prompt tokens (total)	8,839,538
Completion tokens (total)	3,395,880
Cout estime (USD)	8.969223

Metriques derivees :

- taux de modification : $\frac{8856}{9005} \times 100 = 98.35\%$
- taux d erreur : $\frac{4}{9005} \times 100 = 0.0444\%$
- tokens moyens par ligne : prompt ≈ 981.63 , completion ≈ 377.11

4.5 Problemes observes sur le QC

1. **Timeout API sur 4 lignes** : toutes les erreurs du rapport ont le message
ERROR: QC call failed after 4 attempts: Request timed out.
2. **Lignes impactees** :
(2167, data75210, WIKI_C_09888),
(5153, data78196, WIKI_C_10483),
(6419, data79462, WIKI_D_00161),
(7983, data81026, WIKI_C_09529).

5 Script 2 : clean_silver_shard_3_corrected.py

5.1 Role

Ce script applique un pipeline de nettoyage NLP modulaire sur les 4 colonnes cibles :

- darija_arabic
- darija_arabizi
- english
- modern_standard_arabic

5.2 Nettoyages appliques (detail fonctionnel)

5.2.1 Preprocessing global

- suppression artefacts MT globaux : <unk>, @-@
- nettoyage HTML/Markdown/URL/mentions
- gestion des emojis (suppression par default)
- normalisation des espaces

5.2.2 Nettoyage par langue

Anglais

- lowercasing
- expansion des contractions (ex : don't → do not)
- retrait ponctuation/symboles et stopwords
- options : stem/lemma (desactivees par default)

MSA

- normalisation script arabe (diacritiques, tatweel, variantes Alef)
- retrait stopwords MSA
- options clitiques/stemming léger (desactivees par default)

Darija arabe

- normalisation arabe adaptee Darija
- normalisation de variantes lexicales (mapping)
- retrait stopwords Darija

Darija arabizi

- lowercasing
- reduction des repetitions de caracteres
- nettoyage ponctuation/symboles
- suppression des chiffres isolés
- options transliteration vers arabe / drop voyelles (desactivees par default)

5.2.3 Filtres de lignes

- suppression des lignes “metadata contamination”
- suppression optionnelle des lignes MSA avec marqueurs Darija
- suppression optionnelle des lignes de statut **ERROR**
- suppression des lignes avec champ cible vide (apres nettoyage)

5.2.4 Post-clean quality fixes

- suppression de placeholders residuels selon colonne
- collapse des tokens adjacents dupliques
- recalcul de `english_word_count`

6 Resultats de cleaning (rapports JSON)

6.1 Silver cleaned (mode strict)

Source : `artifacts/silver_shard_3_cleaned/cleaning_report.json`

Indicateur	Valeur
Input rows	9005
Dropped rows (total)	175
Dropped metadata rows	1
Dropped MSA-Darija leakage rows	163
Dropped ERROR status rows	4
Dropped empty rows	7
Output rows	8830
Placeholder removals	5
Duplicate token removals	945
english_word_count recomputed	8779

Metriques derivees :

- retention : $\frac{8830}{9005} \times 100 = 98.0566\%$
- drop global : $\frac{175}{9005} \times 100 = 1.9434\%$
- impact MSA leakage : $\frac{163}{9005} \times 100 \approx 1.81\%$

6.2 Gold cleaned (conservation MSA-Darija)

Source : `artifacts/gold_shard_3_cleaned/cleaning_report.json`

Indicateur	Valeur
Input rows	1000
Dropped rows (total)	21
Dropped metadata rows	0
Dropped MSA-Darija leakage rows	0
Dropped ERROR status rows	0
Dropped empty rows	21
Output rows	979
Duplicate token removals	76
english_word_count recomputed	977

Metriques derivees :

- retention : $\frac{979}{1000} \times 100 = 97.9\%$
- toutes les suppressions proviennent des champs vides apres nettoyage.

7 Resultat intermediaire merge gold

Source : `artifacts/gold_shard_3_merge/gold_shard_3.merge_report.json`

Indicateur	Valeur
gold_total_rows	1000
first_input_rows	4499
last_input_rows	500
first_matches_expected_500	0
last_matches_expected_500	500
output_rows	1000

Warning reportee : *First-half file has zero matching data_id values for gold_shard_3 first 500 rows.*

8 Interpretation des resultats EDA comparatifs

Sources notebooks :

- `EDA_gold_shard_3_comparatif.ipynb`
- `EDA_silver_shard_3_comparatif.ipynb`

8.1 Vue d ensemble volumes et retention

Dataset	Source rows	Cleaned rows	Dropped rows	Retention (%)
Gold shard 3	1000	979	21	97.90
Silver shard 3	9005	8830	175	98.0566

Lecture :

- Les deux pipelines conservent la majorite des donnees (retention > 97%).
- Le drop silver est plus eleve en absolu (175 lignes) car il inclut le filtre MSA-leakage en mode strict.

8.2 Evolution des statuts

Gold (source) : GENERATED=749, PARTIALLY_VALIDATED=250, active=1.

Gold (cleaned) : VALIDATED=498, GENERATED=354, PARTIALLY_VALIDATED=127.

Silver (source) : GENERATED=6801, PARTIALLY_VALIDATED=2199, active=5.

Silver (cleaned) : VALIDATED=8830.

Lecture :

- Sur silver, le jeu nettoye est homogene en **VALIDATED**.
- Sur gold, les statuts restent mixtes, ce qui est coherent avec une chaine de preparation differente (merge puis cleaning).

8.3 Taux de changement texte (source vs cleaned)

Comparaison faite sur l'intersection des `data_id` :

Colonne texte	Gold change rate (%)	Silver change rate (%)
<code>darija_arabic</code>	99.2850	99.7282
<code>darija_arabizi</code>	92.4413	95.4360
<code>english</code>	100.0000	100.0000
<code>modern_standard_arabic</code>	98.9785	99.7622

Rows avec au moins un champ texte modifié :

— Gold : 100.0% (979/979)

— Silver : 100.0% (8830/8830)

Lecture :

— Le cleaning est fortement transformationnel, surtout sur `english` (100% change).

— `darija_arabizi` varie un peu moins que les autres colonnes, mais reste > 92% de modifications.

8.4 Longueur des textes et outliers

Colonne	Gold mean src → cln	Silver mean src → cln	Gold max src → cln	Silver max
<code>darija_arabic</code>	129.5530 → 102.9019	126.3861 → 101.3258	3739 → 524	3
<code>darija_arabizi</code>	136.0880 → 114.4076	137.1625 → 112.8159	333 → 307	4
<code>english</code>	146.4870 → 101.0133	147.8856 → 100.9409	566 → 412	3
<code>modern_standard_arabic</code>	123.5510 → 95.1164	142.7377 → 93.0967	335 → 261	1634

Lecture :

— Les longueurs moyennes diminuent systématiquement après cleaning sur les 4 colonnes (gold et silver).

— L'outlier massif en MSA sur silver (max=163453) disparaît après cleaning (max=267), ce qui confirme l'effet de sanitation.

9 Pipeline global du projet

9.1 Pipeline fonctionnel

1. Ingestion des shards bruts :

— Gold : `shards/gold_1k_shards/gold_shard_3.csv`

— Silver : `shards/silver_9k_shards/silver_shard_3.csv`

2. Correction QC multilingue (LLM) via `check_and_correct_mt.py` :

— sortie CSV corrige + rapport JSON + checkpoint JSONL

— exemple : `artifacts/silver_shard_3_qc/silver_shard_3.corrected.auto.csv`

3. Préparation Gold merge via `merge_corrected_gold_shard_3.py` :

— sortie : `artifacts/gold_shard_3_merge/gold_shard_3.corrected.merged.csv`

— audit : `artifacts/gold_shard_3_merge/gold_shard_3.merge_report.json`

4. Cleaning linguistique via `clean_silver_shard_3.corrected.py` :

— sorties cleaned CSV + top words + cleaning report

— silver : `artifacts/silver_shard_3_cleaned/`

— gold : `artifacts/gold_shard_3_cleaned/`

5. EDA comparative des résultats :

— `EDA_gold_shard_3_comparatif.ipynb`

— `EDA_silver_shard_3_comparatif.ipynb`

9.2 Pipeline resume

```
Raw shards (gold/silver)
    |
    v
QC correction (check_and_correct_mt.py)
    |
    +--> qc CSV + report + checkpoint
    |
    v
Gold merge step (merge_corrected_gold_shard_3.py)
    |
    v
Cleaning NLP (clean_silver_shard_3_corrected.py)
    |
    +--> cleaned CSV + top words + cleaning report
    |
    v
EDA comparative notebooks (gold and silver)
```

10 Problemes techniques constates

1. **Timeouts API (QC)** : 4 lignes en echec malgre retries.
2. **Perte potentielle de donnees utiles** : en mode strict, 163 lignes retirees car MSA detectee comme Darija-like.
3. **Sortie de recheck incoherente** : `silver_shard_3.corrected.auto.errors.rechecked.csv` est vide (0 byte) alors que son checkpoint contient 1 entree.
4. **Dependance non exploitee explicitement** : `python-dotenv` est presente dans requirements mais non importee dans les scripts analyses.

11 Recommandations

1. Pour conserver le code-switching MSA/Darija : lancer le cleaning avec `-keep-msa-darija-leakage`.
2. Pour minimiser les pertes : ajouter une option `-keep-empty-target-rows` (actuellement absente).
3. Pour stabiliser les runs QC : reduire `-workers`, augmenter `-retries`, relancer uniquement `-only-status ERROR`.
4. Pour auditabilite : produire un CSV des IDs supprimees par categorie de filtre.
5. Pour hygiene dependances : supprimer `python-dotenv` de requirements ou l'utiliser explicitement.

12 Commandes de reproduction

12.1 QC principal silver

```
python check_and_correct_mt.py \
--input shards/silver_9k_shards/silver_shard_3.csv \
--output artifacts/silver_shard_3_qc/silver_shard_3.corrected.auto.csv \
--report artifacts/silver_shard_3_qc/silver_shard_3.corrected.auto.
report.json
```

12.2 Cleaning silver (mode strict par default)

```
python clean_silver_shard_3_corrected.py \  
  --input artifacts/silver_shard_3_qc/silver_shard_3.corrected.auto.csv \  
  --output-dir artifacts/silver_shard_3_cleaned \  
  --output-name silver_shard_3.corrected.cleaned.csv
```

12.3 Cleaning gold en gardant MSA-Darija

```
python clean_silver_shard_3_corrected.py \  
  --input artifacts/gold_shard_3_merge/gold_shard_3.corrected.merged.csv \  
  --output-dir artifacts/gold_shard_3_cleaned \  
  --output-name gold_shard_3.corrected.cleaned.csv \  
  --keep-msa-darija-leakage --skip-dummy-demo
```

13 Appendice A : extraits JSON utiles

13.1 QC summary (silver)

```
{  
  "total_rows": 9005,  
  "processed_rows": 9005,  
  "changed_rows": 8856,  
  "error_rows": 4,  
  "total_prompt_tokens": 8839538,  
  "total_completion_tokens": 3395880,  
  "estimated_cost_usd": 8.969223  
}
```

13.2 Cleaning summary (silver strict)

```
{  
  "input_rows": 9005,  
  "dropped_rows": 175,  
  "dropped_metadata_rows": 1,  
  "dropped_msa_darija_rows": 163,  
  "dropped_error_status_rows": 4,  
  "dropped_empty_rows": 7,  
  "output_rows": 8830  
}
```

13.3 Cleaning summary (gold keep-msa-darija-leakage)

```
{  
  "input_rows": 1000,  
  "dropped_rows": 21,  
  "dropped_msa_darija_rows": 0,  
  "dropped_empty_rows": 21,  
  "output_rows": 979  
}
```